Разведочный анализ данных (EDA)

Команда VolgaDev · Хакатон М.Видео · 17.10.2026. Цель — описать структуру предоставленных данных, поля, пропуски и распределения, на которых строится пайплайн извлечения характеристик товаров.

Состав данных

Файл	Роль	Объём	Поля	Пропуски
sku_desc.parquet	Вход пайплайна	1 177 200 описаний	sku_id, title, description	0% (заполнены все)
query_clicks.parquet	Поисковый трафик (метрика)	30 991 350 кликов	sku_id, sku_name, sku_brand_name, sku_price, sku_subject_id, sku_seo_id, query_text, sku_position	—
skus.pkl	Эталон (gold set)	546 069 офферов · 6 963 категории	id, available, vendor, model, name, categories, param, атрибуты _search	уточняется по атрибутам

Ключевые выводы

- Основное сырьё — sku_desc.parquet: 1,17 млн карточек, поля заполнены на 100% (пропусков нет), что даёт полный вход для извлечения.
- Эталон для валидации — skus.pkl: 546 тыс. офферов с атрибутами _search (Цвет_search, Модель_search) — те характеристики, что реально работают в фильтрах М.Видео. Они и есть цель извлечения.
- Метрика — query_clicks.parquet: 31 млн кликов позволяет считать traffic-weighted F1 (взвешивание по популярности запросов).
- Распределение: 6 963 уникальные категории — широкий каталог, подтверждает вызов «длинного хвоста» редких значений.

Распределения и пропуски по атрибутам

Итоговая статистика пропусков и распределений атрибутов внутри skus.pkl (per-attribute coverage) дополняется после среза по размеченному каталогу. Предварительно: описание не имеет пропусков (0%), категории разнообразны (6,9 тыс.), эталон _search готов для сверки.

План использования в решении

- Из sku_desc.parquet берём тексты названий/описаний — вход извлечения.
- По skus.pkl верифицируем точность (эталон _search) и coverage.
- По query_clicks.parquet считаем трафик-взвешенную метрику.

Далее: дополнить точные объёмы пропусков и гистограммы заполненности атрибутов по skus.pkl после среза инженером.